

Analiza poveznica
Središta i autoriteti na webu

Bruno Fabulić, Helena Marciuš, Dora Parmač

21. prosinca 2020.

Sadržaj

1	Uvod	1
2	HITS algoritam	2
3	WWW kao usmjereni graf	3
3.1	Matrična formulacija	4
4	Podgraf fokusiran na upit	5
4.1	Konstrukcija S_σ	5
4.2	Web stranica kao upit	6
5	Implementacija HITS algoritma	7
5.1	Implementacija HITS-a u Octaveu	8
5.2	Rezultati	9
5.3	Upit $\sigma = \text{"california"}$	9
5.4	Stranice slične k $p = \text{'www.epa.gov'}$	10
6	Sličnost s bibliometrijskom analizom	13
6.1	Autoriteti i ko-citacije	13
6.2	Hubovi i ko-reference	14
7	Konvergencija algoritma	15
8	Vjerojatnosna analiza	16
9	Average case analiza	17
10	Svojstva HITS algoritma	19

1 Uvod

Budući živimo u svijetu informacija, Internet je dio našeg svakodnevnog života, te imamo pristup do više informacija nego što možemo procesuirati. Zbog toga nam je potrebna metoda za filtriranje informacija. Kao odgovor, javljaju se tehnike za pretraživanje. Njih možemo opisati kao proces koji nam omogućava pretraživanje veće kolekcije dokumenata za specifičnu informaciju koju nazivamo upit (eng. query).

Web je kolekcija dokumenata čije karakteristike ga čine posebno kompleksnim za pretraživanje. Pretraživači su suočeni s problemima kao što je sama veličina Weba, brzina kojom se mijenja i raste, te nedostatkom sustavne organizacije. Procjenjuje se da sadrži preko 45 milijardi stranica što ga čini najvećom kolekcijom dokumenata na svijetu, a to je samo indeksirani dio. Također, dinamičan je (godišnje nastaje milijarde novih dokumenata zbog čega je pretraživačima teško izračunati njihovu relevantnost za postavljene upite) i nije sustavno organiziran jer svatko može stvoriti stranicu u bilo koju svrhu. Podatci konstantno nastaju i nestaju, a poveznice (eng. link) se stvaraju i pucaju jer odredišta postaju nedostupna.

Kao rješenja danog problema, pojavila se metoda analize poveznica. Stranice na webu povezane su hipervezama koju se web pretraživačima važan izvor informacija. Korisne su jer označavaju referencu stranice A na stranicu B što samo po sebi nije značajno korisno. No, ako pretpostavimo da autori stranice koriste poveznice za koje misle da će biti korisne čitatelju i ako su to poveznice na kvalitetne stranice koje obogaćuju sadržaj ili podupiru stajališta autora, onda na njih možemo gledati kao preporuku autora stranice A na stranicu B. Analiza poveznica se uspješno koristi za pronalaženje i indeksiranje novih stranica, rangiranje rezultata pretraživanja, te kategorizaciju web stranica.

2 HITS algoritam

Jedan od algoritama za rangiranje web stranice ovisno o upitu koje ćemo proučavati je Kleinbergov HITS algoritam.

Iz grafa poveznica G stvara se manji graf (eng. neighborhood graph) koji sadržava samo čvorove stranica koje odgovaraju upitu, proširen njihovim 'susjednim' stranicama. Susjedi u ovom slučaju znače set stranica koje poveznicama pokazuju na, ili na njih pokazuju dokumenti iz početnog seta koji odgovara upitu. Takav set stranica može biti jako velik pa se u praksi često ograničava na manji broj prethodnika. Rangiranje se potom vrši prema tom grafu uzimajući u obzir broj linkova vezanih uz čvor svake stranice iz početnog seta. Kao i prije problem je što svaka poveznica vrijedi jednako. Kod upita, algoritam prvo iterativno računa vrijednost središta (eng. hub score) i vrijednost autoriteta (eng. authority score) za svaki čvor iz grafa susjeda. Dokumenti se onda rangiraju prema obje vrijednosti.

Za dokumente s visokim autoritetom smatra se da bi trebali imati relevantni sadržaj. Dokumenti središta trebali bi imati poveznice na relevantne dokumente. Ideja je da bi dokumenti koji pokazuju na mnoge druge mogli biti dobra središta, a dokumenti na koje pokazuju mnogi drugi dokumenti dobri autoriteti.


3 WWW kao usmjereni graf

Svaku kolekciju povezanih web stranica možemo predstaviti usmjerenim grafom $G = (V, E)$. Web stranice predstavljamo vrhovima, tj. V je skup web stranica, a poveznice između stranicama predstavljamo bridovima - za stranice $p_i, p_j \in V$, brid e_{ij} je u E ako postoji poveznica sa stranice p_i na stranicu p_j . Kažemo da je stupanj izlaznosti (out - degree) vrha p_i broj vrhova na koje p_i pokazuje, a stupanj ulaznosti (in-degree) broj vrhova koji pokazuju na p_i .

Kažemo da je vrh i

- dobar izvor informacije o lokaciji kvalitetnog sadržaja ili dobro čvorište (hub) ako sadrži linkove na vrhove koji su dobri autoriteti u smislu sadržavanja kvalitetne informacije
- dobar autoritet (sadrže kvalitetnu informaciju o nekoj temi) ako na njega pokazuju dobri hubovi

Dakle, svakom vrhu, odnosno svakoj stranici p_i pridružujemo uređen par (x_i, y_i) nenegativnih brojeva kao mjeru za "biti dobar autoritet" i "biti dobar hub".



Težine $x_i \geq 0$ i $y_i \geq 0$ definirano rekursivno s:

$$x_i = \sum_{j: e_{ji} \in E} y_j \quad y_i = \sum_{j: e_{ij} \in E} x_j \quad (1)$$

Odnosno, autoritet-vrijednost web stranice je suma hub-vrijednosti svih stranica koje pokazuju na nju. Hub vrijednost web stranice je suma autoritet-vrijednosti web stranica na koje ona pokazuje. Intuitivno, smatramo da je web stranica dobar autoritet ako na nju pokazuju dobri hubovi. Analogno, smatramo da je web stranica dobar hub ako pokazuje na dobre autoritete.

Kako odrediti x_i, y_i ?

Stavimo $x = (x_1 \dots x_n)^T, y = (y_1 \dots y_n)^T$ i

$$L = (L_{i,j})_{i,j=1}^n$$

$$L_{i,j} = \begin{cases} 1 & \text{ako } i \longrightarrow j \\ 0 & \text{inače} \end{cases}$$

Ako gornji princip iteriramo i generiramo nizove $x^{(k)} i y^{(k)} = Lx^{(k)}$ dobijemo $x^{(k+1)} = L^{(k)}y^{(k)}, y^{(k+1)} = Lx^{(k+1)} = LL^T y^{(k)}$.

Te relacije korigiramo normiranjem u

$$x^{(k+1)} = \frac{x^{(k+1)}}{\|x^{(k+1)}\|_2} \quad y^{(k+1)} = \frac{y^{(k+1)}}{\|y^{(k+1)}\|_2}$$

Dakle, dobili smo dva niza generirana metodom potencija za $L^T LiLL^T$. Dobilene matrice imaju iste svojstvene vrijednosti, pa ako je λ_1 dominantna svojstvena vrijednost, onda imamo konvergenciju: postoje $xiy, \|x\|_2 = \|y\|_2 = 1$ tako da je

$$L^T Lx = \lambda_1 x \quad LL^T y = \lambda_1 y$$

3.1 Matrična formulacija

Za usmjereni graf $G = (V, E)$, definiramo matricu linkova:

$$L = \begin{cases} 1, & e_{ij} \in E \\ 0, & e_{ij} \notin E \end{cases}$$

Autoritet-vrijednosti x_i čine vektor autoriteta $x = (x_1, x_2, \dots, x_n)$, a hub vrijednosti čine vektor hubova $y = (y_1, y_2, \dots, y_n)$. Sada se jednačbe (1) mogu zapisati kao

$$x = L^T y \quad y = Lx \quad (2)$$

4 Podgraf fokusiran na upit

Pretpostavimo da je dan upit σ . Želimo pronaći podgraf grafa G na kojem ćemo izvesti algoritam. Mogli bi se ograničiti na skup svih stranica koje spominju upit σ . Međutim, broj takvih stranica može biti vrlo velik što bi uzrokovalo velikim "troškom" kod računanja. Također, kao što smo prije zaključili, najbolji autoriteti možda neće biti u tom skupu.

Htjeli bismo kolekciju S_σ koja ima sljedeća svojstva

1. S_σ je relativno mali skup
2. S_σ sadrži većinom sadrži relevantne stranice
3. S_σ sadrži većinu dobrih autoriteta

4.1 Konstrukcija S_σ

Za zadani upit σ , pronađemo relevantne web stranice i rangiramo ih (npr. broj pojavljivanja upita na stranici, PageRank) i odaberemo k najbolje rangiranih stranica. Na taj način dobivamo skup R_σ koji nazivamo početni skup ("root set"). Taj skup zadovoljava 1. i 2. svojstvo, ali možda ne zadovoljava 3. svojstvo. Koristeći ovaj skup, konstruiramo skup S_σ na sljedeći način: za svaku stranicu p u R_σ , u R_σ dodamo sve stranice na koje p pokazuje i d proizvoljnih stranica koje pokazuju na p .

Ograničenje na broj stranica koje pokazuju na p osigurava da je skup s_σ relativno mali (svojstvo (1)), a iz konstrukcije se vidi da je zadovoljeno svojstvo (2).


Pretpostavimo da je q dobar autoritet za zadani upit. Iako se q možda ne nalazi u R_σ , vrlo je vjerojatno da barem jedna od stranica iz R_σ pokazuje na q pa se stoga q nalazi u S_σ , tj. zadovoljeno je i svojstvo (3).

Podgraf grafa G induciran skupom S_σ označavamo s $G[S_\sigma]$ i na njemu provodimo HITS algoritam.

4.2 Web stranica kao upit

Prethodno opisani postupak može se modificirati za sličan problem - rangiranje sličnih web stranica.

Za zadanu web stranicu p , pronađemo t najbolje rangiranih web stranica koje pokazuju na p . Tako dobivamo početni set R_p . Skup S_p dobivamo na sljedeći način: za svaku stranicu q u R_p , u R_p dodajemo sve stranice na koje q pokazuje i d proizvoljnih stranica koje pokazuju na q . Podgraf grafa G induciran skupom S_p označavamo s $G[S_p]$ i na njemu provodimo HITS algoritam.



Slika 1: Proširivanje root set-a u base set

5 Implementacija HITS algoritma

Iterativno računamo autoritet-vrijednosti i hub-vrijednosti. Sa $x^{(k)}$ i $y^{(k)}$ označimo vrijednost vektora x odnosno y u k -toj iteraciji. Iz jednadžbi (2) slijedi

$$cx^{(k+1)} = L^T Lx^{(k)} \quad cy^{(k+1)} = LL^T y^{(k)} \quad (3)$$

uz početni uvjet $x^{(0)} = y^{(0)} = (1, 1, \dots, 1)$, gdje je c konstanta takva da vrijedi $\|x\|_2 = 1$ i $\|y\|_2 = 1$. Matricu $L^T L$ nazivamo matrica autoriteta, a matricu LL^T nazivamo matrica hubova. Uočimo da su ove matrice simetrične.

Možemo zapisati algoritam:

1. Ulaz: Matrica linkova L
2. Inicijaliziramo $x^{(0)} = (1, 1, \dots, 1)$, $y^{(0)} = (1, 1, \dots, 1)$
3. Računaj k -tu iteraciju

$$x^{(k+1)} = L^T Lx^{(k)} \quad y^{(k+1)} = LL^T y^{(k)}$$

4. Normiraj dobivene vrijednosti

$$x^{(k+1)} = \frac{x^{(k+1)}}{\|x^{(k+1)}\|_2} \quad y^{(k+1)} = \frac{y^{(k+1)}}{\|y^{(k+1)}\|_2}$$

5. Provjeri kriterij zaustavljanja

- Ako kriterij zaustavljanja nije zadovoljen, idi na 3, korak
- Ako je kriterij zaustavljanja zadovoljen, završi

6. Izlaz: Vektori vrijednosti autoriteta, odnosno hubova, x i y

i -ta komponenta vektora x predstavlja autoritet-vrijednost web stranice p_i , a i -ta komponenta vektora y predstavlja hub-vrijednost web stranice p_i .

5.1 Implementacija HITS-a u Octaveu

```
function [] = hits(L, W, n)
C = zeros(n,n);
R = zeros(n,n);
k = 0;
eps = power(10, -5);
xp = ones(n, 1);
yp = ones(n, 1);
x = zeros(n,1);
y = zeros(n,1);
con = 1;
X = (L')*L;
Y = L*(L');

while con
    x = X*(xp);
    x/=norm(x);
    y = Y*(yp);
    y/=norm(y);
    if norm(x-xp) < eps && norm(y-yp) < eps
        con = 0;
    else
        xp=x;
        yp=y;
        ++k;
    endif
endwhile

[x_sort, ix] = sort(x, 'descend');
[y_sort, iy] = sort(y, 'descend');

disp("Prvih dvadeset autoriteta ");
for i = 1:20
    disp(W(ix(i)));
endfor
disp("Prvih dvadeset hubova ");
for i = 1:20
    disp(W(iy(i)));
endfor
```

5.2 Rezultati

Prikazujemo rezultate naše implementacije HITS algoritma

5.3 Upit $\sigma = \text{"california"}$

Algoritam je izveden na skupu web stranica koji je nastao postupkom opisanim u (4.1). Podaci su preuzeti sa <http://www.cs.cornell.edu/courses/cs685/2002fa/>.

HITS	Indgr	URL
1	2	http://www.ca.gov/
2	6	http://www.sen.ca.gov/
3	8	http://www.assembly.ca.gov/
4	3	http://www.leginfo.ca.gov/calaw.html
5	1	http://www.yahoo.com/
6	11	http://www.house.gov/
7	12	http://www.fedworld.gov/
8	26	http://www.lao.ca.gov/
9	24	http://www.dot.ca.gov/
10	42	http://www.courtinfo.ca.gov/
11	9	http://www.epa.gov/
12	19	http://www.census.gov/
13	5	http://www.berkeley.edu/
14	21	http://www.lycos.com/
15	41	http://www.ss.ca.gov/
16	27	http://www.caltech.edu/
17	23	http://goldmine.cde.ca.gov/
18	24	http://www.excite.com/
19	56	http://www.ftb.ca.gov/
20	62	http://www.csun.edu/

Tablica 1: Rangiranje autoriteta za upit "california"

HITS	Outdgr	URL
1	1	http://www.water.ca.gov/www.gov.sites.html
2	24	http://www.llnl.gov/OCM/Go_To.html
3	3	http://www.ca.gov/s/search/servers.html
4	5	http://california.findlaw.com/CA10_california_governemnt/index.html
5	28	http://www.occn.org/links.htm
6	13	http://www5.onramp.net/smcgarry/argonaut/caform.htm
7	103	http://www.cyberg8t.com/mlms/Program.html
8	14	http://www.siscr.cz/db/abcd/fil151.html
9	41	http://kerncounty.com/rma/links.htm
10	40	http://www.autoaccident.com/calres.html
11	72	http://www.mother.com/minao/lunrpage/
12	116	http://www.research.digital.com/SRC/virtual-tourist/final/CaliforniaGov-state.htm
13	2	http://www.igs.berkeley.edu:8880/library/cgpp.html
14	74	http://www.ci.torrance.ca.us/city/dept/library/GOVERN.HTM
15	15	http://www.ilrg.com/gov/ca.html
16	63	http://www.nocall.org/calif.html
17	16	http://www.pirg.org/calpirg/links.htm
18	97	http://www.cccd.edu/dis/gov.html
19	238	http://www.calbar.org/2lin/2gov.htm
20	12	http://www.asiadragns.com/education/north_america/united_states/california/

Tablica 2: Rangiranje hubova za upit "california"

5.4 Stranice slične k $p = \text{'www.epa.gov'}$

Algoritam je izveden na skupu web stranica nastalim postupkom opisanim u (4.2). Podaci su preuzeti sa <http://www.cs.cornell.edu/courses/cs685/2002fa/>.

HITS	Indgr	URL
1	2	http://www.epa.gov/
2	3	http://www.yahoo.com/
3	4	http://www.noaa.gov/
4	169	http://www.usitc.gov/
5	83	http://www.nrc.gov/
6	72	http://www.nps.gov/
7	133	http://www.fema.gov/
8	21	http://lcweb.loc.gov/homepage/lchp.html
9	134	http://www.iadb.org/
10	5	http://www.mckinley.com/
11	13	http://www.lycos.com/
12	222	http://www.exim.gov/
13	223	http://www.nara.gov/
14	2	http://www.epa.gov
15	325	http://www.clark.net/pub/peace/PeaceCorps.html
16	255	http://www.un.org/
17	224	http://govinfo.kerr.orst.edu/
18	182	http://www.irs.ustreas.gov/
19	283	http://www.ustr.gov/
20	9	http://www.doc.gov/

Tablica 3: Rangiranje autoriteta za stranicu "www.epa.gov"

HITS	Outdgr	URL
1	1	http://cyberspud.com/gov.html
2	21	http://www.law.vill.edu/Fed-Agency/fedwebloc.html
3	22	http://www.law.vill.edu/Fed-agency/fedwebloc.html
4	12	http://tor-pw1.netcom.ca/dhera/usagov.html
5	28	http://www.kcc.state.ks.us/energy/links.htm
6	3	http://www.phoenix.net/blp/misc.html
7	41	http://www.deq.state.la.us/other_st.htm
8	11	http://sio.ucsd.edu/sp_progs/cetc/whc/c_monitoring/inven.html
9	10	http://kierkegaard.ifas.ufl.edu/
10	9	http://apu.edu/rconover/bookmark.html
11	52	http://neon.mems.cmu.edu/MSE/other.html
12	44	http://www.trans-action.com/websites.htm
13	48	http://www.state.nc.us/EHNR/ee/links/eebkms.htm
14	7	http://www.sgc.colorado.edu/resources/dans_resources.html
15	14	http://www.imt.net/dcouncil/envgov.html
16	2	http://www.ridgeco.com/kzenv.html
17	34	http://www.media-wave.com/Bookmarks/Env.html
18	80	http://www.nes-inc.com/links.htm
19	57	http://www.holonet.net/strategies/EarthRise/INTERNET-RESOURCES2
20	79	http://www.ecotradenet.com/book1.htm

Tablica 4: Rangiranje hubova za web stranicu "www.epa.gov"

6 Sličnost s bibliometrijskom analizom

Bibliometrija se bavi kvantitavnim proučavanjem pisanih dokumenata i pojava kao što su produktivnost autora, citiranje, disperzija članaka, učestalost riječi.

Ko-citacija dokumenata a i b je mjera sličnosti koja se definira kao frekvencija citiranja ta dva dokumenta, tj. broj dokumenata koji citiraju dokumente a i b . Što je veći broj dokumenata koji citiraju a i b , njihova je ko-citacija veća pa je veća vjerojatnost da su a i b semantički slični.

Slično, ko-referenca dokumenata a i b je mjera sličnosti koje se definira kao broj dokumenata na koje a i b imaju referencu. Ako a i b imaju veću ko-referencu, veća je vjerojatnost da a i b obrađuju sličnu temu.

Na sličan način možemo definirati mjere sličnosti između autoriteta, odnosno hubova.

6.1 Autoriteti i ko-citacije

Ako na web stranice p_i i p_j pokazuje veći broj stranica, vjerojatnije je da su one na neki način slične. Za web stranice p_i i p_j definiramo ko-citacije kao broj web stranica koje pokazuju na p_i i p_j . Matrično se ovo može zapisati kao

$$C_{ij} = \sum_k L_{ki} L_{kj} = \sum_k (L^T)_{ik} L_{kj} = (L^T L)_{ij} \quad (4)$$

uz $C_{ii} = 0$. Također vrijedi simetrija, tj. $C_{ij} = C_{ji}$.

Označimo sa d_i stupanj ulaznosti stranice p_i . d_i možemo računati kao

$$d_i = \sum_k L_{ki} = \sum_k L_{ki} L_{ki} = (L^T L)_{ii} \quad (5)$$

jer je $L_{ki} = L_{ki}^2$ jer je $L_{ki} = 1$ ili $L_{ki} = 0$.

Definiramo matricu stupnjeva ulaznosti D :

$$D = \text{diag}(d_1, d_2, \dots, d_n) \quad (6)$$

Tada matrica autoriteta ima sljedeću strukturu:

$$L^T L = D + C \quad (7)$$

odnosno, matrica autoriteta je zbroj matrice ko-citacija i matrice stupnjeva ulaznosti.

6.2 Hubovi i ko-reference

Za web stranice p_i i p_j definiramo ko-reference kao broj web stranica na koje pokazuju p_i i p_j . Matrično se ovo može zapisati kao

$$R_{ij} = \sum_k L_{ik} L_{jk} = \sum_k L_{ik} (L^T)_{kj} = (LL^T)_{ij} \quad (8)$$

uz $R_{ii} = 0$. Također vrijedi simetrija, tj. $R_{ij} = R_{ji}$.

Označimo sa o_i stupanj izlaznosti stranice p_i . o_i možemo računati kao

$$o_i = \sum_k L_{ik} = \sum_k L_{ik} L_{ik} = (LL^T)_{ii} \quad (9)$$

jer je $L_{ik} = L_{ik}^2$ jer je $L_{ik} = 1$ ili $L_{ik} = 0$.

Definiramo matricu stupnjeva izlaznosti O :

$$O = \text{diag}(o_1, o_2, \dots, o_n) \quad (10)$$

Tada matrica autoriteta ima sljedeću strukturu:

$$LL^T = O + R \quad (11)$$

odnosno, matrica hubova je zbroj matrice ko-referenca i matrica stupnjeva izlaznosti.

Također, imamo nejednakost:

$$\max\{0, o_i + o_k - n\} \leq R_{ik} \leq \min\{o_i, o_k\} \quad (12)$$

Direktna posljedica ove tvrdnje je $R_{ik} = 0$ ako $o_i = 0$ ili $o_k = 0$. Dakle, ako web stranica p_i stupanj izlaznosti 0, tada je i -ti red LL^T jednak 0. Iz jednadžbe (3), slijedi da hub score mora biti 0.

7 Konvergencija algoritma

Primijetimo da je $L^T L = (LL^T)^T$. Stoga, matrice $L^T L$ i LL^T imaju iste svojstvene vrijednosti. Kako su to realne i simetrične matrice, njihove svojstvene vrijednosti su također realne.

Neka su $\lambda_1, \lambda_2, \dots, \lambda_n$ svojstvene vrijednosti ovih matrica poredane padajuće po apsolutnoj vrijednosti, tj. vrijedi $|\lambda_1| \geq |\lambda_2| \geq \dots \geq |\lambda_n|$. Pretpostavimo da vrijedi $|\lambda_1| > |\lambda_2|$. Svojstvenu vrijednost λ_1 nazivamo dominantna svojstvena vrijednost.

Teorem 7.1. *Nizovi $x^{(1)}, x^{(2)}, x^{(3)} \dots$ i $y^{(1)}, y^{(2)}, y^{(3)} \dots$ konvergiraju limesima x^* i y^* .*

Dokaz. Neka je $G = (V, E)$, gdje je $V = \{k_1 \dots k_n\}$ i neka je A adjunktna matrica grafa G . Element na mjestu (i, j) jednak je 1 ako je (p_i, p_j) brid grafa G , a 0 inače. Lako se provjeri da operacije I i O mogu biti napisane kao $x \leftarrow A^T y$ i $y \leftarrow Ax$, redom. Tada je x_k jedinični vektor u smjeru $(A^T A)^{k-1} A^T z$, a y_k jedinični vektor u smjeru $(AA^T)^k z$.

Linearna algebra nam kaže da ako je M simetrična $n \times n$ matrica i vektor v nije ortogonalan svojstvenom vektoru $\omega_1(M)$ tada jedinični vektor u smjeru Mkv konvergira prema $\omega_1(M)$ kako se k povećava. Također, M ima samo nenegativne ulaze, pa glavni svojstveni vektor od M ima samo nenegativne vrijednosti.

Posljedično, z nije ortogonalan $\omega_1(AA^T)$ pa tada niz $\{y_k\}$ konvergira prema y^* . Na sličan način se pokaže da ako je $\lambda_1 \neq 0$, tada $A^T z$ nije ortogonalan na $\omega_1(AA^T)$. Iz toga slijedi da niz $\{x_k\}$ konvergira prema x^* . \square

Dokaz ovog teorem daje sljedeći rezultat.

Teorem 7.2. *x^* je dominantni svojstveni vektor matrice $L^T L$, a y^* je dominantni svojstveni vektor matrice LL^T .*

8 Vjerojatnosna analiza

Analizirali smo strukturu autoriteta i hubova. Rezultati jednadžbe (7) pokazuju zanimljivu vezu između ko-citacija i stupnja ulaznosti: općenito, čvorovi s velikim izlaznim stupnjem će imati velike ko-citacije s ostalim čvorovima samo zato jer imaju više ulaznih linkova/bridova. Slično, veliku ko-referencu povezujemo s velikim izlaznim brojem linkova.

Ovakva intuicija se može precizirati ako pretpostavimo da (web) graf ima nasumično raspoređen graf fiksnog stupnja te koristeći vjerojatnosnu analizu na očekivanim vrijednostima ko-citacije i ko-reference. Općenito govoreći, web graf je nasumičan graf - milijuni pojedinaca i organizacija kreiraju web stranice za različite svrhe. Predlaže se da je web bolje opisan nasumičnim grafom fiksnog stupnja, unutar kojeg su čvorovi stupnjeva $\{d_1 \dots d_n\}$ prvo dani, a bridovi su nasumično raspoređeni između čvorova koji podliježu ograničenjima stupnjeva čvorova. Stoga imamo sljedeću tvrdnju:

Propozicija 8.1. *Prosječna vrijednost ko-citacija dana je formulom*

$$\langle C_{ik} \rangle = \frac{d_i d_k}{n-1} \quad (13)$$

Dokaz. Pretpostavimo da je $d_i \geq d_k$. Tada iz jednadžbe (3) vidimo da ima barem d_k elemenata različitih od 0, što je INNER PRODUCT i-tog retka i k-tog stupca matrice L. Promotrimo slučaj kada je q-ti red u k-tom stupcu jednak 1. Vjerojatnost da je vrijednost u i-tom stupcu jednaka 1 jest:

$$P(L_{qi} = 1) = \frac{C_{n-2}^{d_i-1}}{C_{n-1}^{d_i}} = \frac{d_i}{n-1}$$

Ovdje je $C_{n-1}^{d_i}$ ukupan broj svih mogućih rasporeda d_i jedinica u i-tom stupcu, a $C_{n-2}^{d_i-1}$ je ukupan broj svih mogućih rasporeda ako je jedinica u retku q. Dakle,

$$\langle C_{ik} \rangle = \sum_q \langle L_{qi}, L_{qk} \rangle = \sum_q \langle L_q \rangle = d_k * P(L_{qi} = 1)$$

odakle slijedi (13) □

Iz ove analize, vidimo da će vrh i s velikim izlaznim stupnjem d_i imati veliku ko-citaciju s drugim vrhovima, a ako to usporedimo s vrhom j koji ima manji izlazni stupanj d_j tj. ako je $d_i > d_j$, tada je:

$$\langle C_{ik} \rangle > \langle C_{jk} \rangle \quad \forall k, k \neq i, k \neq j$$

Iz ove probabilističke jednadžbe, zaključujemo da je C_{ik} veći od C_{jk} većinu vremena, što nije nužno istina u svakom slučaju. Praktičnosti radi, kažemo da u *prosijeku* vrijedi $C_{ik} \gtrsim C_{jk}$.

Na sličan se način ova analiza može primijeniti za izlazni stupanj i ko-referencu hubova matrice LL^T . Imamo:

$$\langle R_{ik} \rangle = \frac{o_i o_k}{n-1}$$

Ako je $o_i > o_j$, tada $\langle R_{ik} \rangle > \langle R_{jk} \rangle$, odnosno kažemo da $R_{ik} \gtrsim R_{jk}$ vrijedi u *prosijeku*.

9 Average case analiza

Zbog dosadašnjih analiza, sada možemo zamijeniti matricu autoriteta njihovim prosječnim vrijednostima.

Teorem 9.1. *Matrica autoriteta $L^T L$ u prosječnom slučaju, uz uvjet*

$$d_i + d_j < n + 1 \quad (14)$$

za svaki i, j ima sljedeće svojstvene vrijednosti i svojstvene vektore:

1. *Za svojstvene vrijednosti vrijedi*

$$\lambda_1 > \hat{d}_1 > \lambda_2 > \hat{d}_2 > \dots > \lambda_n > \hat{d}_n \quad (15)$$

2. *k -ti svojstveni vektor je*

$$\mathbf{u}_k = \left(\frac{d_1}{\lambda_k - \hat{d}_1}, \frac{d_2}{\lambda_k - \hat{d}_2}, \dots, \frac{d_n}{\lambda_k - \hat{d}_n} \right)^T \quad (16)$$


Web stranice indeksiramo tako da je $d_1 > d_2 > \dots > d_n$ i vrijedi $\hat{d}_i = d_i - \frac{d_i^2}{n-1}$.

Dokaz. Koristeći izraz (13), prosječna matrica autoriteta je

$$\langle L^T L \rangle = \langle D \rangle + \langle C \rangle = \text{diag}(\hat{d}_1, \dots, \hat{d}_n) + \frac{1}{n-1} dd^T \quad (17)$$

□

Analogan rezultat vrijedi za matricu hubova LL^T .



Slika 2: Svojstveni vektori jednadžbe

Korolar 9.1.1. *Elementi dominantnog vektora \mathbf{u}_1 su padajući, tj. za $i < j$ vrijedi*

$$u_1(i) - u_1(j) > 0 \quad (18)$$

Dokaz.

$$u_1(i) - u_1(j) = \frac{d_i}{\lambda_1 - \hat{d}_i} - \frac{d_j}{\lambda_1 - \hat{d}_j} = \frac{(d_i - d_j)[\lambda_1 - d_i d_j(n-1)]}{(\lambda_1 - \hat{d}_i)(\lambda_1 - \hat{d}_j)} > 0 \quad (19)$$

jer je

$$\lambda_1 - d_i d_j(n-1) \stackrel{(2)}{>} \hat{d}_i - d_i d_j(n-1) = d_i(1 - (d_i + d_j)/(n-1)) \stackrel{(14)}{>} 0 \quad (20)$$

□

Iz ovo korolara, možemo zaključiti da je, u prosječnom slučaju, poredak web stranica po autoritet-vrijednostima jednak poretku po stupnju ulaznosti.

Analogan rezultat vrijedi za matricu hubova LL^T , tj. u prosječnom slučaju, poredak web stranica po hub-vrijednosti jednak je poretku po stupnju izlaznosti.

10 Svojstva HITS algoritma

Nekoliko zanimljivih rezultata slijedi direktno iz prethodnog teorema:

1. **Organiziranje web stranica.** Rangiranje autoriteta, je u prosjeku, identično kao rangiranje stranica pomoću ulaznih stupnjeva. Kako bi nam bilo to jasnije, imamo sljedeću tvrdnju:

Korolar 10.0.1. *Elementi glavnog svojstvenog vektora u_1 monotonopadaju.*

Dokaz. Za svaki $i < j$:

$$u_1(i) - u_1(j) = \frac{d_i}{\lambda_1 - \hat{d}_i} - \frac{d_j}{\lambda_1 - \hat{d}_j} = \frac{(d_i - d_j)[\lambda_1 - \frac{d_i d_j}{n-1}]}{(\lambda_1 - \hat{d}_i)(\lambda_1 - \hat{d}_j)} > 0$$

□

Iz ovoga zaključujemo da je rangiranje web stranica pomoću njihovih authority scorova isto kao i rangiranje prema ulaznim stupnjevima. Praktična primjena ovih rezultata jest da je jednostavno brojanje ulaznih bridova kao algoritam rangiranja učinkovito i efikasno.

2. **Jedinstvenost.** Ako je $d_1 > d_2$, tada je glavni svojstveni vektor $L^T L$ jedinstven i različit od drugog glavnog svojstvenog vektora.
3. **Konvergencija.** Konvergencija HITS algoritma može biti dosta brza. Početni vektor $x^{(0)} = (1 \dots 1)$ ima vrlo malo preklapanja s ostalim svojstvenim vektorima ($x^{(0)} * u_k, k > 1$) jer svi oni sadrže negativne vrijednosti čvora. Koristeći $L^T L = \lambda_1 u_1 u_1^T + \lambda_2 u_2 u_2^T + \dots$ nakon k iteracija, imamo:

$$x^{(k)} = c_1 \lambda_1^k u_1 + c_2 \lambda_2^k u_2 + \dots$$

gdje je $c_2 \ll c_1$ zbog malih preklapanja između $x^{(0)}$ i u_2

4. **Web zajednice.** HITS algoritam se uvijek koristio za identificiranje mnogih web zajednica koristeći različite svojstvene vrijednosti. Glavni svojstveni vektor definira dominantnu web zajednicu. Svaki sporedni svojstveni vektor definira dvije zajednice, jednu s nenegativnim $\{i | u_k(i) \geq 0\}$ i drugu s negativnim vrijednostima $\{i | u_k(i) < 0\}$

Literatura

- [1] Chris Ding, Hongyuan Zha, Xiaofeng He, Parry Husbands, Horst Simon
Link Analysis: Hubs and Authorities on the World Wide Web.
<http://ranger.uta.edu/~chqding/papers/hits5.pdf> 2001.
- [2] Soumen Chakrabarti, Byron E. Dom, David Gibson, Jon Kleinberg, Ravi Kumar, Prabhakar Raghaan, Sridhar Rajagopalan, Andrew Tomkins
Mining the Link Structure of the World Wide Web.
<https://www.cs.cornell.edu/home/kleinber/ieee99-web.pdf>
1999.
- [3] Jon M. Kleinberg *Authoritative Sources in a Hyperlinked Environment*.
<https://www.cs.cornell.edu/home/kleinber/auth.pdf>